赵怡浩

（+86）138-5468-6001 zhaoyh98@pku.edu.cn
个人主页 微信：13854686001

资历摘要

教育背景：北京大学本科、直博
研究方向：面向人工智能基础设施的高效资源管理
科研经历：已发表论文七篇（CCF-A 类一作论文四篇），已授权专利一项

教育经历

北京大学 **中国北京**
计算机学院，博士 *2021 年 9 月-2026 年 6 月*
导师：刘譞哲教授 合作指导：金鑫长聘副教授
所获荣誉：北京大学校长奖学金（**北京大学研究生最高奖学金**）、计算机学院学术十杰（提名，**前 2%**）等

北京大学 **中国北京**
图灵班（计算机科学专业），学士 *2017 年 9 月- 2021 年 7 月*
GPA: 3.78/4.0 (前 7%)

实习经历

小米 **中国北京**
MiMo 大模型后训练框架，研发实习生 *2025 年 8 月-2026 年 2 月*
合作主导完成科研项目“面向智能体强化学习框架的工具资源管理系统”

上海人工智能实验室 **中国北京**
AI 训练与计算，研发实习生 *2024 年 6 月-2025 年 2 月*
主导完成科研项目“面向大模型推理负载的延迟优化共享调度系统”

字节跳动 **中国北京**
机器学习系统，研发实习生 *2021 年 1 月-2022 年 2 月，2023 年 3 月-2023 年 9 月*
主导完成科研项目“面向深度学习训练负载的多资源共享调度系统”和“大规模 GPU 集群的训推混部系统”

项目经历

深度学习集群 **面向大模型推理负载的延迟优化共享调度系统丨国产算力验证** *2024 年 6 月-2025 年 2 月*

- 针对大模型推理负载资源利用率低和现有共享方法的延迟劣化明显等挑战，设计面向大模型推理负载的延 迟优化共享系统，提出负载特征感知、延迟优化的负载（重）放置、请求调度和统一缓存技术；
- **降低大模型推理负载的归一化延迟达 13.6 倍，提升 SLO 满足率达 3.6 倍**，系统已在英伟达 GPU 和国产算力华为 Ascend NPU 进行适配和效果验证。

大规模 GPU 集群的训推混部系统丨字节万卡集群部署 *2023 年 3 月-2023 年 9 月*

- 针对大规模推理集群资源利用率低的问题和现有共享技术难以安全高效真实部署的挑战，设计训推混部系统，提出多层级多方面的推理负载性能保障机制、动态的训练负载调度机制和共享负载安全保障机制；
- 对在线负载影响可接受的情况下，**提升集群 GPU 利用率达 2.9 倍，超卖资源率达 71.2%**；
- 相关工作发表于 CCF-A 类期刊 SCIS，已部署于**字节跳动万卡集群**，每年约节省上亿元云服务运维成本。

服务器无感知的弹性分布式深度学习训练集群系统 *2021 年 9 月-2022 年 3 月*

- 针对现有训练集群需要系统专家知识、无法感知完成期限等不足，参与设计服务器无感知的弹性训练集群调度系统，优化完成期限感知的调度算法并进行广泛验证；
- 提高截止时间前完成的任务比例达 7.7 倍，显著降低开发者使用集群的复杂度；
- 相关工作发表于 CCF-A 类国际会议 ASPLOS’23。

面向深度学习训练负载的多资源共享调度系统 *2021 年 1 月-2021 年 9 月*

- 针对深度学习训练负载资源瓶颈多样的发展趋势，设计面向训练负载的多资源共享调度系统，提出多资源交错共享机制和基于匹配的负载调度算法；
- 提高训练负载的执行效率达 3.6 倍，提高集群的资源利用率达 36%；
- 相关工作发表于 CCF-A 类国际会议 SIGCOMM’22，系统代码开源并取得所有审查徽章。

面向国产算力的大模型推理负载 PD 分离系统 *2025 年 4 月-2025 年 8 月*

- PD 分离被英伟达、DeepSeek 等国内外公司广泛用于大模型推理负载加速，针对 PD 分离在国产算力的适配实现传输加速、灵活扩展和动态调配三项技术；
- 在昇腾 NPU 和沐曦 GPU 上，提高大模型推理的逐字延迟 48%、吞吐 21%；
- 相关工作已开源。

数据中心网络 **面向大规模数据中心的安全高效网络迁移规划系统 | Meta 部署** *2022 年 5 月-2023 年 1 月*

- 针对大规模数据中心网络迁移规划面临的安全性和高效性的挑战，设计基于搜索和动态规划的安全高效规划算法，提出领域特定的搜索空间压缩、基于优先级的快速搜索和压缩表示技术；
- 在满足所有迁移限制的情况下，**最小化迁移代价，并加快方案生成时间达 381 倍**；
- 相关工作发表于 CCF-A 类国际会议 SIGCOMM’23，已部署于 **Meta 全球二十余个地区的上百个数据中心**。

深度学习平台 **基于 Kubernetes 的 MLOps 平台 | 平台 demo** *2023 年 6 月-2025 年 2 月*

- 负责平台的开发和部署。该平台旨在为用户提供易用高效的深度学习训推部署平台，支持一键式负载上传、自动环境配置、算力用量评估、智能负载调度与管理；
- 该平台集成了多项国际领先的系统技术，并进行了多地应用部署。集成了包括 ElasticFlow、DistServe 在内的多个学术界领先的深度学习训练/推理调度算法和优化技术，支持 NVIDIA GPU 和华为 Ascend NPU。已在北京大学、东南大学、北京昇腾创新人工智能有限公司等部署测试。

论文列表

已发表论文（七篇，其中四篇 CCF-A 类一作）

[1] **[SCIS’24, CCF-A, 已部署于字节跳动]** Xuanzhe Liu (导师), **Yihao Zhao**, Shufan Liu, Xiang Li, Yibo Zhu, Xin Liu, Xin Ji. MuxFlow: Efficient GPU Sharing in Production-Level Clusters with More Than 10,000 GPUs.

[2] **[TPDS’24, CCF-A]** Diandian Gu, **Yihao Zhao**, Peng Sun, Xin Jin, Xuanzhe Liu. GreenFlow: A Carbon Efficient Scheduler for Deep Learning Workloads.

[3] **[MoNeTec’24, Best Paper Award] Yihao Zhao**, Xuanzhe Liu, Xin Jin. How Useful is Communication Scheduling for Distributed Training?

[4] **[SIGCOMM’23, CCF-A, 已部署于 Meta] Yihao Zhao***, Xiaoxiang Zhang*, Hang Zhu, Ying Zhang, Zhaodong Wang, Yuandong Tian, Alex Nikulkov, Joao Ferreira, Xuanzhe Liu, Xin Jin. Klotski: Efficient and Safe Network Migration of Large Production Datacenters.

[5] **[ASPLOS’23, CCF-A]** Diandian Gu*, **Yihao Zhao***, Yinmin Zhong, Yifan Xiong, Zhenhua Han, Peng Cheng, Fan Yang, Gang Huang, Xin Jin, Xuanzhe Liu. ElasticFlow: An Elastic Serverless Training Platform for Distributed Deep Learning.

[6] **[SIGCOMM’22, CCF-A] Yihao Zhao**, Yuanqiang Liu, Yanghua Peng, Yibo Zhu, Xuanzhe Liu, Xin Jin. Multi-Resource Interleaving for Deep Learning Training.

[7] **[ECCV’20, CCF-B, 视觉领域三大顶会之一] Yihao Zhao**, Ruihai Wu, Hao Dong. Unpaired Image-to-Image Translation using Adversarial Consistency Loss.

在投论文（两篇 CCF-A 一作在投）

[1] **[In submission] Yihao Zhao,** Jiadun Chen, Peng Sun, Lei Li, Xuanzhe Liu, Xin Jin. SeaLLM: Service-Aware and Latency-Optimized Resource Sharing for Large Language Model Inference.

[2] **[In submission]** Bangjun Xiao*, **Yihao Zhao*,** Xiangwei Deng, Shihua Yu, Yuxing Xiang, Huaqiu Liu, Qiying Wang, Liang Zhao, Hailin Zhang, Xuanzhe Liu, Xin Jin, Fuli Luo. ALOER: Action-Level Orchestration for External Resources for Agentic Reinforcement Learning.

奖励

北京大学图灵研究生计划奖学金	2025 年 11 月
北京大学灵均领航奖学金	2025 年 10 月
北京大学优秀科研奖	2025 年 10 月
北京大学计算机学院小米杯学术十杰（提名）	2024 年 12 月

北京大学校长奖学金	2023 年 1 月
北京大学九坤奖学金	2022 年 10 月
北京大学三等奖学金	2020 年 10 月
北京大学图灵奔竞一等奖学金	2019 年 10 月
北京大学奔驰奖学金	2018 年 10 月
北京大学三好学生	2018 年 10 月，2020 年 10 月

相关报道

- 大规模 GPU 集群的训推混部相关工作被中国科学、科学网、北大官微、北大科研等报道；
- 服务器无感知的弹性分布式深度学习训练系统被科学网、N 方智源、北大官微等报道；
- 面向大规模数据中心的安全高效网络迁移规划系统被北大新闻网等报道；
- 碳排放效率优化的弹性模型训练系统被北大科研等报道。